

Contexto de aplicación.

Twitter(X) se ha convertido en un importante canal de comunicación en tiempos de emergencia.

La ubicuidad de los teléfonos inteligentes permite a la gente anunciar en tiempo real una emergencia que esté observando. Por eso, cada vez más organismos se interesan por el seguimiento programado de Twitter (por ejemplo, organizaciones de ayuda en catástrofes y agencias de noticias). Sin embargo, en algunos casos, no es claro si las palabras que una persona usa están anunciando un desastre real. Por ejemplo, un tweet puede contener la palabra "ABLAZE" (en llamas), pero el autor puede estar usando esa palabra de manera metafórica y no literal para referirse a un incendio real.

Objetivo de machine learning

El objetivo de este problema de aprendizaje automático es predecir si ciertos tweets están hablando sobre desastres reales o si es simplemente una metáfora u otro uso no relacionado con desastres. Dado un tweet específico y su contenido textual, el modelo de machine learning debe clasificar el tweet dependiendo si es un "desastre real" o "no desastre".

Dataset

El total de datos a predecir es de 10875 tweets, que han sido clasificados manualmente, es decir, etiquetados por humanos como tweets sobre desastres reales o no.

El tamaño de la dataset es de unos 1.3MB de información en los conjuntos de datos train.csv y test.csv.

Cada muestra del conjunto de entrenamiento y prueba contiene la siguiente información distribuidos en los .csv de la siguiente manera:

En test.csv:

- **id**- un identificador único para cada tweet
- **text** - el texto del tweet
- **location** - la ubicación de donde fue enviado(puede estar en blanco)
- **keyword**- una palabra clave concreta del tweet (puede estar en blanco)

Y al dataset de train.csv se le añade una columna para saber si el desastre es real(1) o no(0):

- **target**- this denotes whether a tweet is about a real disaster (1) or not (0)

Métricas

En general, al tratarse de un problema de clasificación, se usarán métricas comunes a este tipo de problemas, con el objetivo de visualizar la efectividad del modelo desde diferentes perspectivas.

- **Sparse Categorical Accuracy:** Dado que es un problema de categorización, esta métrica es útil para saber qué tanto las predicciones aciertan el valor esperado.
- **Precisión:** resulta conveniente para comprobar qué tantos valores categorizados como positivos, son realmente positivos.
- **Recall:** servirá para detectar cuántos valores positivos son correctamente calificados.

Referencias y resultados previos

En cuanto a resultados previos, este problema se ha tratado frecuentemente en la comunidad de Kaggle, por lo que hay un punto de partida amplio, en concreto hemos partido de dos trabajos:

Audevart, A. (2023) *Kerasnlp starter notebook disaster tweets*, Kaggle. Available at: <https://www.kaggle.com/code/alexia/kerasnlp-starter-notebook-disaster-tweets>

Thite, S. (2023) *NLP disaster tweets using bert*, Kaggle. Available at: <https://www.kaggle.com/code/sunilthite/nlp-disaster-tweets-using-bert>

Las métricas fueron obtenidas en la documentación de Keras:

Tf.keras.metrics.sparse_categorical_accuracy : tensorflow V2.14.0 (2023) TensorFlow. Available at: https://www.tensorflow.org/api_docs/python/tf/keras/metrics/SparseCategoricalAccuracy

Tf.keras.metrics.precision : tensorflow V2.14.0 (2023) TensorFlow. Available at: https://www.tensorflow.org/api_docs/python/tf/keras/metrics/Precision

tf.keras.metrics.Recall : tensorflow V2.14.0 (2023) TensorFlow. Available at: https://www.tensorflow.org/api_docs/python/tf/keras/metrics/Recall